

Méthodes numériques pour l'estimation du SCR par modèle interne

Komlan Doigté Katakou¹

¹Université Claude Bernard Lyon 1,
Master 1 Mathématiques appliquées

2025–2026

Résumé — Le cadre réglementaire *Solvabilité II* impose aux assureurs de détenir un niveau de fonds propres suffisant pour honorer leurs engagements même en cas d'événements défavorables exceptionnels. Au cœur de ces exigences se trouve le *Solvency Capital Requirement* (SCR), défini comme le capital nécessaire pour absorber, avec un niveau de confiance de 99,5% à horizon un an, les pertes résultant de scénarios sévères. Ce capital peut être estimé soit par la formule standard du régulateur, soit par un modèle interne validé par l'autorité de contrôle — option généralement retenue par les grands groupes en raison de la complexité de leurs profils de risque. Dans les deux cas, la distribution de perte n'admet pas de forme analytique : son évaluation nécessite le calcul d'espérances conditionnelles sous une double mesure de probabilité, l'une réelle et l'autre risque-neutre.

La méthode naturelle d'estimation par modèle interne, celle des *simulations imbriquées*, se révèle être une double peine : computationnellement très coûteuse en $O(\varepsilon^{-3})$, elle produit de surcroît une estimation systématiquement biaisée positivement du SCR, conduisant à une surestimation du risque réel. La méthode *Multi-Level Monte Carlo* (MLMC) est conçue pour remédier à ce double inconvénient : en exploitant une hiérarchie de niveaux d'approximation et un échantillonnage adaptatif, elle permet d'atteindre théoriquement une complexité de $O(\varepsilon^{-2} |\log \varepsilon|^2)$.

Ce rapport est le fruit d'une première immersion dans ce problème : partant du cadre mathématique de BAUER, BERGMANN et REUSS (2010), j'ai étudié les fondements des deux méthodes et produit une implémentation numérique de la première sur un modèle actif-passif Black-Scholes / Vasicek calibré sur données historiques allemandes. La méthode des simulations imbriquées a fait l'objet d'une analyse rigoureuse — biais asymptotique, optimisation de l'allocation du budget de calcul par multiplicateurs de Lagrange — et d'une implémentation C++ complète, avec quelques approximations sur la modélisation des flux et de l'actualisation. Notre estimation du SCR présente un écart d'environ 6% à la hausse avec la valeur de référence de BAUER, BERGMANN et REUSS (2010), dont les sources sont discutées. Pour MLMC, dont la théorie a été étudiée en profondeur et présentée ici intégralement, l'implémentation numérique n'a pas encore été menée à terme.

Mots-clés : SCR, Solvabilité II, modèle interne, simulations imbriquées, MLMC, biais asymptotique.

Table des matières

1	Formalisation du problème	3
1.1	Espace de probabilité filtré et processus d'état	3
1.2	Modèle de passifs et profits actionnariaux	4
1.3	Capital disponible	4
1.4	Définition du SCR	5
2	Méthode des simulations imbriquées	6
2.1	Construction de l'estimateur	6
2.2	Décomposition et sources d'erreur	7
2.3	Biais de l'estimateur du quantile	8
2.4	Optimisation de l'allocation des simulations	9
3	Méthode Multi-Level Monte Carlo (MLMC)	10
3.1	Le problème traité et son expression canonique	11
3.2	Décomposition télescopique et estimateur MLMC	11
3.3	Conditions de Giles et régimes de complexité	12
3.4	La difficulté du quantile : discontinuité et échantillonnage adaptatif	13
3.5	Valeurs théoriques de α, β, γ	14
4	Implémentation et résultats	14
4.1	Modèle actif-passif	14
4.2	Résultats	15
	Conclusion	16

1. Formalisation du problème

Cette section pose le cadre mathématique dans lequel les deux méthodes d'estimation seront étudiées. On formalisera successivement l'espace de probabilité, les processus de marché, les grandeurs bilan de l'assureur, et la définition précise du SCR comme quantile d'une distribution de perte.

1.1. Espace de probabilité filtré et processus d'état

Soit $T > 0$ la maturité du contrat le plus long du portefeuille. On se fixe un espace de probabilité filtré complet :

$$(\Omega, \mathcal{F}, \mathbb{P}, \mathbb{F} = (\mathcal{F}_t)_{t \in [0, T]}),$$

où :

- Ω est l'espace des états du monde ;
- $\mathcal{F}$ est une σ -algèbre sur Ω ;
- $\mathbb{P}$ est la *mesure de probabilité historique* (ou *réelle*), c'est-à-dire la loi effective des facteurs de marché ;
- $\mathbb{F} = (\mathcal{F}_t)_{t \in [0, T]}$ est une filtration satisfaisant les conditions habituelles (complète et continue à droite), avec $\mathcal{F}_t$ représentant l'information disponible à l'instant t .

L'incertitude sur les profits futurs de l'assureur relève de l'aléa sur l'évolution de plusieurs facteurs de marché : taux d'intérêt, indices actions, spreads de crédit, ... On modélise ces facteurs par un processus d'état markovien.

Hypothèse 1.1 (Processus d'état markovien). *L'incertitude des marchés financiers est modélisée par un processus de Markov d -dimensionnel suffisamment régulier :*

$$Y = (Y_t)_{t \in [0, T]} = (Y_{t,1}, \dots, Y_{t,d})_{t \in [0, T]},$$

appelé **processus d'état**. Il représente les d facteurs de risque sous-jacents. Par la propriété de Markov, pour tous $0 \leq s \leq t \leq T$ et tout borélien $A \subset \mathbb{R}^d$:

$$\mathbb{P}(Y_t \in A \mid \mathcal{F}_s) = \mathbb{P}(Y_t \in A \mid Y_s). \quad (1)$$

On définit également le **numéraire**, c'est-à-dire le compte bancaire accumulé au taux sans risque instantané :

$$B_t = \exp\left(\int_0^t r_u du\right), \quad \text{où } r_t = r(Y_t) \geq 0. \quad (2)$$

Ce processus sert de référence pour l'actualisation des capitaux futurs.

Hypothèse 1.2 (Absence d'arbitrage et mesure risque-neutre). *Le marché est sans friction et sans arbitrage. Il en résulte l'existence d'une mesure de probabilité $\mathbb{Q}$, dite **mesure risque-neutre**, vérifiant :*

- (i) $\mathbb{Q}$ est équivalente à $\mathbb{P}$: $\mathbb{Q} \sim \mathbb{P}$ (elles coïncident sur les ensembles de mesure nulle) ;
- (ii) sous $\mathbb{Q}$, le prix de tout actif négociable actualisé par B_t est une $(\mathbb{Q}, \mathbb{F})$ -martingale :

$$\mathbb{E}^{\mathbb{Q}}\left[\frac{S_T}{B_T} \mid \mathcal{F}_t\right] = \frac{S_t}{B_t}, \quad \forall 0 \leq t \leq T.$$

La densité de Radon-Nikodym de $\mathbb{Q}$ par rapport à $\mathbb{P}$ est donnée par le théorème de Girsanov :

$$\left. \frac{d\mathbb{Q}}{d\mathbb{P}} \right|_{\mathcal{F}_t} = \exp\left(-\int_0^t \lambda_s dW_s - \frac{1}{2} \int_0^t \|\lambda_s\|^2 ds\right), \quad (3)$$

où $W = (W_t)_{t \in [0, T]}$ est un mouvement brownien sous $\mathbb{P}$ et $\lambda = (\lambda_t)$ est le **prix de marché du risque**. Sous $\mathbb{Q}$, le processus $\tilde{W}_t = W_t + \int_0^t \lambda_s ds$ est un mouvement brownien.

1.2. Modèle de passifs et profits actionnariaux

Les engagements de l'assureur génèrent des flux de trésorerie aux dates $t = 1, \dots, T$. Ces flux incorporent toute la complexité contractuelle : garanties minimales, participation aux bénéfices, politique de dividendes.

Hypothèse 1.3 (Modèle de flux actionnariaux). *Il existe des fonctionnelles mesurables $f_1, \dots, f_T$ telles que les profits actionnariaux vérifient :*

$$X_t = f_t(Y_s, s \in [0, t]), \quad t = 1, \dots, T.$$

On suppose de plus que $X_t \in L^2(\mathbb{P})$ pour tout t .

1.3. Capital disponible

L'évaluation quantitative de la solvabilité repose sur la notion de **capital disponible** (AC, pour *Available Capital*), défini comme la valeur de marché nette de l'assureur, c'est-à-dire la différence entre la valeur de marché des actifs et celle des passifs. Ce concept coïncide avec les *fonds propres* dans la terminologie *Solvabilité II*.

Pour des raisons de simplicité, nous supposons que le capital disponible coïncide avec la **Valeur Intrinsèque de Marché** (MCEV) :

$$AC_t = \text{MCEV}_t, \quad t = 0, 1.$$

Cette égalité se justifie par le fait que, dans le cadre de Solvabilité II, les ajustements entre MCEV et capital disponible (marge de risque, éligibilité de certains instruments) sont négligés.

La MCEV se décompose en deux composantes :

$$\text{MCEV}_t = \text{ANAV}_t + \text{PVFP}_t,$$

où ANAV_t (*Adjusted Net Asset Value*) est la valeur nette ajustée des actifs incorporels et des plus-values latentes, et PVFP_t (*Present Value of Future Profits*) est la valeur actuelle, sous mesure risque-neutre, des flux futurs attribuables aux actionnaires.

À $t = 0$, on a donc :

$$AC_0 = \text{ANAV}_0 + \underbrace{\mathbb{E}^{\mathbb{Q}}\left[\sum_{t=1}^T B_t^{-1} X_t\right]}_{=: V_0 = \text{PVFP}_0}. \quad (4)$$

À $t = 1$, le capital disponible intègre le profit de la première année X_1 non encore distribué :

$$AC_1 = \text{ANAV}_1 + V_1 + X_1, \quad (5)$$

où V_1 est la valeur, à $t = 1$, des profits futurs restants. C'est l'espérance conditionnelle sous $\mathbb{Q}$ sachant l'information $\mathcal{F}_1$:

$$V_1 := \mathbb{E}^{\mathbb{Q}} \left[\sum_{t=2}^T B_{1,t}^{-1} X_t \mid \mathcal{F}_1 \right], \quad B_{1,t} := \exp \left(\int_1^t r_u du \right). \quad (6)$$

Remarque 1.1. Le calcul de V_0 et V_1 nécessite des simulations Monte Carlo sous $\mathbb{Q}$: aucune forme analytique n'est disponible dès que les fonctionnelles f_t modélisent des options et garanties dans les contrats. C'est la source de toute la complexité numérique étudiée dans ce rapport.

1.4. Définition du SCR

L'assureur est considéré solvable sur l'horizon d'un an si et seulement si $\mathbb{P}(\text{AC}_1 \geq 0) \geq 99,5\%$. La directive *Solvabilité II* reformule cette exigence en termes de quantile d'une perte actualisée.

On définit la **perte annuelle actualisée** au taux sans risque i par :

$$L := \text{AC}_0 - \frac{\text{AC}_1}{1+i}. \quad (7)$$

Définition 1.1 (SCR). Le *Solvency Capital Requirement* est le quantile d'ordre $\alpha = 99,5\%$ de la perte L :

$$\boxed{\text{SCR} := F_L^{-1}(\alpha) = \inf \{ x \in \mathbb{R} \mid \mathbb{P}(L > x) \leq 1 - \alpha \},} \quad (8)$$

où F_L désigne la fonction de répartition de L .

Cette définition est équivalente à l'exigence de solvabilité : $\mathbb{P}(\text{AC}_1 \geq 0) \geq 99,5\%$ si et seulement si $\text{AC}_0 \geq \text{SCR}$.

Remarque

L'estimation du SCR se heurte à deux grandes difficultés.

- **Première difficulté :** La perte L implique deux mesures de probabilité : les scénarios externes $(Y_t)_{t \in [0,1]}$ sont générés sous $\mathbb{P}$ (loi réelle), tandis que V_1 est une espérance sous $\mathbb{Q}$ (mesure risque-neutre). Cette double structure est intrinsèque au problème et ne peut pas être éliminée.
- **Deuxième difficulté :** V_1 est une espérance conditionnelle sachant $\mathcal{F}_1$. Pour chacun des N scénarios externes, il faudrait calculer une espérance différente, ce qui conduit à N problèmes de valorisation Monte Carlo imbriqués.

La propriété de Markov de Y (Hypothèse 1.1) permet de réduire la conditionnelle : il existe une fonction déterministe v telle que :

$$V_1 = v(Y_1, D_1), \quad (9)$$

où :

$$v(y, d) := \mathbb{E}^{\mathbb{Q}} \left[\sum_{t=2}^T B_{1,t}^{-1} f_t(Y_s, s \leq t) \mid (Y_1, D_1) = (y, d) \right]. \quad (10)$$

La conditionnelle porte donc uniquement sur l'état (Y_1, D_1) du marché et du portefeuille à $t = 1$, et non sur toute la trajectoire passée.

C'est cette réduction qui rend le problème traitable, mais loin d'être facile : estimer $v(y, d)$ pour chaque scénario externe reste la tâche numériquement intensive, et c'est précisément ce que les deux méthodes étudiées dans ce rapport cherchent à résoudre efficacement.

2. Méthode des simulations imbriquées

La méthode des simulations imbriquées est la méthode de référence pour l'estimation du SCR par modèle interne. Son principe est direct : simuler un grand nombre de scénarios de marché sur un an (scénarios *externes*) sous $\mathbb{P}$, puis, pour chacun d'eux, relancer un ensemble de simulations sur l'horizon restant (scénarios *internes*) sous $\mathbb{Q}$ pour estimer la valeur des engagements futurs. La double boucle de simulation résulte directement de la double mesure probabiliste inhérente au problème, identifiée à la section 1.

Cette section établit les propriétés statistiques de l'estimateur ainsi obtenu — en particulier son biais positif systématique — et dérive les conditions d'optimalité de l'allocation de simulations.

2.1. Construction de l'estimateur

Étape 1 : estimation de AC_0

Le capital disponible initial $AC_0 = ANAV_0 + V_0$ (voir équation (4)) nécessite l'estimation de :

$$V_0 = \mathbb{E}^{\mathbb{Q}} \left[\sum_{t=1}^T B_t^{-1} X_t \right].$$

On génère K_0 trajectoires i.i.d. sous $\mathbb{Q}$: $(Y_t^{(k)})_{t \in [0, T]}$, $k = 1, \dots, K_0$, en calculant pour chacune les taux $r_t^{(k)} = r(Y_t^{(k)})$, les flux $X_t^{(k)} = f_t(Y_s^{(k)}, s \leq t)$ et les facteurs d'actualisation $B_t^{(k), -1} = \exp(-\int_0^t r_u^{(k)} du)$. L'estimateur de Monte Carlo est :

$$\widehat{V}_0 = \frac{1}{K_0} \sum_{k=1}^{K_0} \sum_{t=1}^T B_t^{(k), -1} X_t^{(k)}. \quad (11)$$

Par la loi forte des grands nombres, $\widehat{V}_0 \xrightarrow{p.s.} V_0$. Puisque les trajectoires sont i.i.d., l'estimateur est sans biais et :

$$\text{Var}(\widehat{V}_0) = \frac{\sigma_0^2}{K_0}, \quad \sigma_0^2 := \text{Var}^{\mathbb{Q}} \left[\sum_{t=1}^T B_t^{-1} X_t \right]. \quad (12)$$

On obtient ainsi $\widehat{AC}_0 = ANAV_0 + \widehat{V}_0$.

Étape 2 : scénarios externes

On génère N trajectoires i.i.d. sous $\mathbb{P}$ sur $[0, 1]$: $(Y_s^{(i)})_{s \in [0, 1]}$, $i = 1, \dots, N$. Pour chaque scénario externe i , on extrait à $t = 1$: l'état de marché $Y_1^{(i)}$, la valeur de portefeuille $D_1^{(i)}$, le profit réalisé $X_1^{(i)}$ et la valeur nette ajustée $ANAV_1^{(i)}$.

Étape 3 : scénarios internes et estimation de $V_1^{(i)}$

Pour chaque scénario externe i , on doit estimer $v(Y_1^{(i)}, D_1^{(i)})$ — la valeur des engagements futurs vue depuis l'état $(Y_1^{(i)}, D_1^{(i)})$ à $t = 1$. On génère K_1 trajectoires internes sous $\mathbb{Q}$, initialisées en $(Y_1^{(i)}, D_1^{(i)}) : (Y_s^{(i,k)})_{s \in (1, T]}$, $k = 1, \dots, K_1$. Pour chaque trajectoire interne (i, k) , on calcule les flux futurs $X_t^{(i,k)} = f_t(Y_1^{(i)}, D_1^{(i)}, Y_u^{(i,k)}, u \in (1, t])$ pour $t = 2, \dots, T$, puis la valeur actualisée :

$$PV_1^{(i,k)} = \sum_{t=2}^T B_{1,t}^{(i,k),-1} X_t^{(i,k)},$$

où $B_{1,t}^{(i,k),-1} = \exp(-\int_1^t r_u^{(i,k)} du)$. L'estimateur de $v(Y_1^{(i)}, D_1^{(i)})$ est la moyenne empirique :

$$\widehat{V}_1^{(i)} = \frac{1}{K_1} \sum_{k=1}^{K_1} PV_1^{(i,k)}. \quad (13)$$

On en déduit l'estimateur du capital disponible à $t = 1$:

$$\widehat{AC}_1^{(i)} = \text{ANAV}_1^{(i)} + \widehat{V}_1^{(i)} + X_1^{(i)}. \quad (14)$$

Étape 4 : estimation du SCR

On pose $\hat{z}_i = -\widehat{AC}_1^{(i)}$ pour $i = 1, \dots, N$. Ces N réalisations estimées de $Z = -AC_1$ fournissent une distribution empirique bruitée. En notant $\hat{z}_{(1)} \leq \dots \leq \hat{z}_{(N)}$ les statistiques d'ordre et $m = \lfloor N\alpha + \frac{1}{2} \rfloor$, l'estimateur du SCR est :

$$\widehat{\text{SCR}} = \widehat{AC}_0 + \frac{\hat{z}_{(m)}}{1+i}. \quad (15)$$

Remarque

La complexité computationnelle est $O(K_0) + O(N \times K_1)$. Pour des paramètres typiques ($K_0 = 1,5 \times 10^6$, $N = 320\,000$, $K_1 = 300$), cela représente $\sim 10^8$ simulations, soit plusieurs dizaines de secondes même sur du matériel moderne.

2.2. Décomposition et sources d'erreur

L'estimateur $\widehat{\text{SCR}}$ présente trois sources d'erreur distinctes :

- (i) l'estimation de V_0 avec K_0 trajectoires ;
- (ii) l'estimation de la distribution de $-AC_1$ avec N scénarios ;
- (iii) l'estimation de chaque $V_1^{(i)}$ avec K_1 simulations internes.

La décomposition précise de l'erreur quadratique moyenne en est la formalisation.

Lemme 2.1 (Décomposition de la MSE). *Sous l'indépendance de $\widehat{AC}_0$ et $(\hat{z}_i)_{i=1}^N$ (garantie par la séparation des échantillons) :*

$$\text{MSE}(\widehat{\text{SCR}}) = \underbrace{\frac{\sigma_0^2}{K_0}}_{(i)} + \underbrace{\frac{\text{Var}(\hat{z}_{(m)})}{(1+i)^2}}_{(ii)} + \underbrace{\frac{[\mathbb{E}(\hat{z}_{(m)}) - z_\alpha]^2}{(1+i)^2}}_{(iii)}, \quad (16)$$

où $z_\alpha = F_{-AC_1}^{-1}(\alpha)$ est le vrai quantile d'ordre α de $-AC_1$.

Démonstration. On pose $A = \widehat{AC}_0$ et $Q = \hat{z}_{(m)}/(1+i)$, indépendants par construction. En développant :

$$\begin{aligned} \text{MSE} &= \mathbb{E}[(A + Q - \text{SCR})^2] \\ &= \mathbb{E}[(A - AC_0)^2] + \mathbb{E}[(Q - z_\alpha/(1+i))^2] \\ &\quad + 2 \underbrace{\mathbb{E}[A - AC_0]}_{=0} \cdot \mathbb{E}[Q - z_\alpha/(1+i)]. \end{aligned}$$

Le terme croisé s'annule car $\mathbb{E}[A] = AC_0$ (non-biais de $\widehat{V}_0$). La décomposition biais-variance de chaque terme carré donne (16). $\square$

Le terme (i) est classique : $\sigma_0^2/K_0 \rightarrow 0$ en $O(K_0^{-1})$. Les termes (ii) et (iii) tiennent au bruit d'estimation de chaque $V_1^{(i)}$: même si l'estimateur $\widehat{V}_1^{(i)}$ est sans biais pour $v(Y_1^{(i)}, D_1^{(i)})$, la statistique d'ordre de la distribution bruitée ($\hat{z}_i$) est un estimateur biaisé du vrai quantile z_α . C'est l'objet du théorème suivant.

2.3. Biais de l'estimateur du quantile

Pour quantifier le terme (iii) de (16), on introduit l'erreur d'estimation renormalisée :

$$\tilde{Z}^{K_1} := \sqrt{K_1} \frac{\widehat{V}_1 - v(Y_1, D_1)}{1+i}. \quad (17)$$

Par le théorème central limite appliqué aux K_1 simulations internes, conditionnellement à (Y_1, D_1) :

$$\tilde{Z}^{K_1} \xrightarrow{\mathcal{L}} \mathcal{N}(0, \sigma_1^2(Y_1, D_1)), \quad (18)$$

où la variance conditionnelle est :

$$\sigma_1^2(y, d) := \frac{1}{(1+i)^2} \text{Var}^{\mathbb{Q}} \left[\sum_{t=2}^T B_{1,t}^{-1} X_t \mid (Y_1, D_1) = (y, d) \right]. \quad (19)$$

Ce terme mesure l'incertitude résiduelle des flux futurs conditionnellement à l'état du marché à $t = 1$. Il est strictement positif tant que les flux ne sont pas déterministes sachant (Y_1, D_1) .

Proposition 2.1 (Biais asymptotique de l'estimateur du quantile, (GORDY et JU-NEJA 2010)). *Supposons que la densité f_L de la perte L soit lipschitzienne au voisinage du SCR, et que $\tilde{Z}^{K_1}$ admette des moments d'ordre 4 finis. Alors :*

$$\mathbb{E} \left[\frac{\hat{z}_{(m)}}{1+i} \right] - \frac{z_\alpha}{1+i} = \frac{\theta_\alpha}{K_1 \cdot f_L(\text{SCR})} + o\left(\frac{1}{K_1}\right) + O\left(\frac{1}{N}\right), \quad (20)$$

où le coefficient de biais est :

$$\theta_\alpha := -\frac{1}{2} \frac{\partial}{\partial u} \left[f_L(u) \mathbb{E}[\sigma_1^2(Y_1, D_1) \mid L = u] \right] \Big|_{u=\text{SCR}}. \quad (21)$$

Corollaire 2.1 (Signe du biais). $\theta_\alpha > 0$, donc $\mathbb{E}[\widehat{\text{SCR}}] > \text{SCR}$: l'estimateur surestime systématiquement le SCR.

Démonstration. On réécrit θ_α en intégrant par rapport à z : en notant $g(u, z)$ la densité jointe de $(L, \tilde{Z}^{K_1})$, et en utilisant $\sigma_1^2(Y_1, D_1) = \mathbb{E}[(\tilde{Z}^{K_1})^2 | Y_1, D_1]$:

$$\theta_\alpha = -\frac{1}{2} \int_{-\infty}^{+\infty} z^2 \frac{\partial g}{\partial u}(u, z) dz \Big|_{u=\text{SCR}}. \quad (22)$$

Dans la queue droite de L , où se situe le SCR pour $\alpha = 99,5\%$, la densité de la perte est décroissante : $f'_L(\text{SCR}) < 0$. Sous l'hypothèse que la densité conditionnelle de $\tilde{Z}^{K_1}$ sachant $L = u$ varie régulièrement avec u , on a $\partial_u g(u, z)|_{u=\text{SCR}} < 0$ pour tout z . Puisque $z^2 \geq 0$ et l'intégrale d'une fonction négative est négative, on conclut $\theta_\alpha > 0$. L'équation (20) donne alors immédiatement $\mathbb{E}[\widehat{\text{SCR}}] > \text{SCR}$. $\square$

Interprétation. L'estimation bruitée de V_1 introduit un aléa supplémentaire dans chaque $\widehat{AC}_1^{(i)}$, étalant artificiellement la distribution empirique des pertes autour de sa vraie distribution. Un estimateur de quantile extrême appliqué à une distribution artificiellement étalée renvoie une valeur plus grande que le vrai quantile : c'est le mécanisme générateur du biais.

Remarque

Du point de vue réglementaire, ce biais est conservateur : l'assureur surcapitalise. Pour un groupe dont le SCR est de l'ordre du milliard d'euros, même un biais de quelques pour cent se traduit par des centaines de millions d'euros d'actifs immobilisés inutilement, avec un coût d'opportunité réel.

2.4. Optimisation de l'allocation des simulations

On cherche à minimiser la MSE totale pour un budget de calcul fixé Γ (nombre total de simulations), avec $K_0 + NK_1 = \Gamma$.

En combinant (16) avec le résultat asymptotique de variance de (GORDY et JUNEJA 2010) :

$$\text{Var}(\hat{z}_{(m)}) \approx \frac{\alpha(1-\alpha)}{Nf_L^2(\text{SCR})} + \frac{C_1}{K_1f_L^2(\text{SCR})}, \quad C_1 := \mathbb{E}[\sigma_1^2(Y_1, D_1) | L = \text{SCR}], \quad (23)$$

et en intégrant le terme de biais au carré (terme dominant en θ_α^2/K_1^2), on obtient l'approximation :

$$\text{MSE} \times (1+i)^2 \approx \underbrace{\frac{\sigma_0^2}{K_0}}_{\text{erreur sur } V_0} + \underbrace{\frac{\theta_\alpha^2}{K_1^2 f_L^2}}_{\text{biais}} + \underbrace{\frac{\alpha(1-\alpha)}{N f_L^2}}_{\text{variance empirique}} + \underbrace{\frac{C_1}{K_1 f_L^2}}_{\text{variance interne}}, \quad (24)$$

en notant $f_L = f_L(\text{SCR})$.

Résolution par multiplicateurs de Lagrange

Le problème de minimisation s'écrit :

$$\min_{K_0, K_1, N > 0} \text{MSE} \quad \text{sous } K_0 + NK_1 = \Gamma.$$

Le Lagrangien est :

$$\mathcal{L}(K_0, K_1, N, \lambda) = \text{MSE} \times (1+i)^2 + \lambda(K_0 + NK_1 - \Gamma).$$

Les conditions de premier ordre donnent :

$$\begin{cases} \partial_{K_0} \mathcal{L} = 0 \Rightarrow \lambda = \frac{\sigma_0^2}{K_0^2}, \end{cases} \quad (25a)$$

$$\begin{cases} \partial_{K_1} \mathcal{L} = 0 \Rightarrow \frac{2\theta_\alpha^2}{K_1^3 f_L^2} + \frac{C_1}{K_1^2 f_L^2} = \lambda N, \end{cases} \quad (25b)$$

$$\begin{cases} \partial_N \mathcal{L} = 0 \Rightarrow \lambda K_1 = \frac{\alpha(1-\alpha)}{N^2 f_L^2}. \end{cases} \quad (25c)$$

En éliminant λ entre (25a) et (25c) :

$$K_0^* = \frac{\sigma_0 f_L \sqrt{\alpha(1-\alpha)}}{\sqrt{K_1}} \cdot N. \quad (26)$$

En substituant dans (25b) (terme dominant θ_α^2/K_1^3 pour K_1 grand) :

$$\boxed{N^* \approx \frac{\alpha(1-\alpha)K_1^2}{2\theta_\alpha^2}}. \quad (27)$$

Complexité asymptotique

En substituant (27) dans (26) et dans la contrainte de budget, on vérifie que le budget optimal à K_1 fixé est :

$$\Gamma^*(K_1) = K_0^* + N^* K_1 = O(K_1^{5/2}) + O(K_1^3) = O(K_1^3).$$

Pour atteindre une précision $\text{MSE} = O(\varepsilon^2)$, le biais dominant impose $K_1 = O(\varepsilon^{-1})$ (d'après (20)), d'où :

$$\Gamma^*(\varepsilon) = O(\varepsilon^{-3}). \quad (28)$$

C'est la complexité inhérente à la méthode des simulations imbriquées : atteindre une précision deux fois meilleure coûte huit fois plus cher.

Limites pratiques

Les formules (26) et (27) font intervenir trois quantités inconnues : σ_0 , $f_L(\text{SCR})$ et θ_α . Si σ_0 peut être estimé à partir des simulations de V_0 , l'estimation de $f_L(\text{SCR})$ nécessite une estimation de densité dans la queue extrême de la distribution ($\alpha = 99,5\%$), et celle de θ_α requiert d'estimer une dérivée dans cette même région. Même avec $N = 100\,000$ scénarios, moins de 500 points tombent dans la région du quantile, rendant ces estimations très imprécises. En pratique, les paramètres de simulation sont donc fixés de façon empirique plutôt qu'optimale.

Cette complexité $O(\varepsilon^{-3})$ et ces difficultés pratiques justifient le développement des deux méthodes alternatives étudiées dans les sections suivantes.

3. Méthode Multi-Level Monte Carlo (MLMC)

La section 2 a établi que la complexité des simulations imbriquées est $O(\varepsilon^{-3})$. La présente section décrit la méthode MLMC, fondée sur la *décomposition télescopique*

(GILES 2008). L'adaptation de cette méthode au calcul d'un quantile nécessite en outre l'échantillonnage adaptatif proposé par (BROADIE, DU et MOALLEMI 2011) et intégré dans le cadre MLMC par (GILES et HAJI-ALI 2019), dont nous présentons la théorie ; son implémentation s'est heurtée à un blocage discuté en section 4.

3.1. Le problème traité et son expression canonique

Le SCR est la valeur c^* solution de $\mathbb{P}(L > c^*) = 1 - \alpha$. Calculer c^* revient à inverser la fonction de survie $c \mapsto \mathbb{P}(L > c)$. On a :

$$L > c \iff AC_0 - \frac{AC_1}{1+i} > c \iff AC_1 < (1+i)(AC_0 - c). \quad (29)$$

Or, d'après (5) et (6), le capital disponible à $t = 1$ s'écrit $AC_1 = ANAV_1 + V_1 + X_1$, où $V_1 = \mathbb{E}^{\mathbb{Q}}[\cdot | Y]$ est lui-même une espérance conditionnelle sous $\mathbb{Q}$. En posant :

$$X := AC_1 - (1+i)(AC_0 - c), \quad (30)$$

Sachant Y , l'aléa résiduel de X est entièrement sous $\mathbb{Q}$: le signe de X est donc déterminé par celui de $\mathbb{E}^{\mathbb{Q}}[X | Y]$. On a $L > c \iff X < 0$, d'où :

$$\mathbb{P}(L > c) = \mathbb{P}(\mathbb{E}^{\mathbb{Q}}[X | Y] < 0) = \mathbb{E}[\mathbb{H}(-\mathbb{E}^{\mathbb{Q}}[X | Y])], \quad (31)$$

où $\mathbb{H}(\cdot)$ est la fonction de Heaviside et $Y = (Y_1, D_1)$ l'état du marché à $t = 1$. C'est précisément la forme $\mathbb{E}[\mathbb{H}(\mathbb{E}[X | Y])]$ étudiée par (GILES et HAJI-ALI 2019), ce qui rend MLMC applicable.

3.2. Décomposition télescopique et estimateur MLMC

Le principe de base (Giles 2008)

Pour chaque scénario externe $Y = (Y_1, D_1)$ et chaque niveau l , on estime $\mathbb{E}^{\mathbb{Q}}[X | Y]$ par une moyenne Monte Carlo de $K_l = M^l$ simulations internes sous $\mathbb{Q}$:

$$Y_l := \frac{1}{K_l} \sum_{k=1}^{K_l} X^{(k)}, \quad (32)$$

où les $X^{(k)}$ sont des réalisations i.i.d. de X conditionnellement à Y . Par la loi des grands nombres, $Y_l \xrightarrow{p.s.} \mathbb{E}^{\mathbb{Q}}[X | Y]$ quand $K_l \rightarrow \infty$. La qualité de l'approximation croît avec l : Y_0 est grossière et peu coûteuse ($K_0 = 1$), Y_L est fine et très coûteuse ($K_L = M^L$).

Notre quantité d'intérêt est $\mathbb{E}[\mathbb{H}(-Y_L)] \approx \mathbb{P}(L > c)$. En appliquant l'identité télescopique à cette espérance :

$$\mathbb{E}[\mathbb{H}(-Y_L)] = \mathbb{E}[\mathbb{H}(-Y_0)] + \sum_{l=1}^L \mathbb{E}[\mathbb{H}(-Y_l) - \mathbb{H}(-Y_{l-1})]. \quad (33)$$

L'estimateur MLMC estime indépendamment chaque terme par une moyenne empirique sur N_l scénarios externes i.i.d. :

$$\hat{\eta}_L^{MLMC} = \frac{1}{N_0} \sum_{i=1}^{N_0} \mathbb{H}(-Y_0^{(i)}) + \sum_{l=1}^L \frac{1}{N_l} \sum_{i=1}^{N_l} [\mathbb{H}(-Y_l^{(i)}) - \mathbb{H}(-Y_{l-1}^{(i)})]. \quad (34)$$

Le couplage. Pour que les corrections $H(-Y_l^{(i)}) - H(-Y_{l-1}^{(i)})$ aient une faible variance, $Y_l^{(i)}$ et $Y_{l-1}^{(i)}$ doivent être couplés : ils partagent le même scénario externe $(Y_1^{(i)}, D_1^{(i)})$, et les K_{l-1} simulations internes du niveau grossier sont un sous-ensemble des K_l simulations du niveau fin. Ainsi, quand K_l est grand, $Y_l^{(i)} \approx Y_{l-1}^{(i)}$ et leur différence de Heaviside est généralement nulle.

Lemme 3.1 (Non-biais et variance). $\hat{\eta}_L^{MLMC}$ est sans biais pour $\mathbb{E}[H(-Y_L)]$ et sa variance est :

$$\text{Var}(\hat{\eta}_L^{MLMC}) = \frac{V_0}{N_0} + \sum_{l=1}^L \frac{V_l}{N_l}, \quad V_l := \text{Var}[H(-Y_l) - H(-Y_{l-1})]. \quad (35)$$

Démonstration. Par linéarité de l'espérance et télescopage :

$$\mathbb{E}[\hat{\eta}_L^{MLMC}] = \mathbb{E}[H(-Y_0)] + \sum_{l=1}^L \mathbb{E}[H(-Y_l) - H(-Y_{l-1})] = \mathbb{E}[H(-Y_L)].$$

Pour la variance : les N_l scénarios externes de chaque niveau l sont tirés indépendamment de ceux des autres niveaux, donc les $L + 1$ estimateurs sont indépendants et leurs variances s'additionnent. $\square$

Remarque

L'estimateur est sans biais pour $\mathbb{E}[H(-Y_L)]$, non pour $\mathbb{P}(L > c)$ exactement. Il subsiste un biais de troncature $|\mathbb{E}[H(-Y_L)] - \mathbb{P}(L > c)|$, dû au fait que Y_L n'est qu'une approximation de $\mathbb{E}^Q[X | Y]$. Ce biais est contrôlé par la condition (i) de l'Hypothèse 3.1.

3.3. Conditions de Giles et régimes de complexité

Hypothèse 3.1 (Conditions de Giles, (GILES 2015)). Il existe $\alpha, \beta, \gamma > 0$, avec la condition de compatibilité $\alpha \geq \frac{1}{2} \min(\beta, \gamma)$ qui garantit que le biais converge au moins aussi vite que la racine carrée de la variance, et des constantes $C_1, C_2, C_3 > 0$, tels que pour tout $l \geq 0$:

- (i) **Biais** : $|\mathbb{E}[H(-Y_l)] - \mathbb{P}(L > c)| \leq C_1 M^{-\alpha l}$,
- (ii) **Variance des corrections** : $V_l \leq C_2 M^{-\beta l}$,
- (iii) **Coût par scénario au niveau l** : $\mathcal{C}_l \leq C_3 M^{\gamma l}$.

Proposition 3.1 (Complexité MLMC, (GILES 2015)). Sous l'Hypothèse 3.1, pour atteindre $\text{MSE} \leq \varepsilon^2$, le coût optimal est :

$$\mathcal{C}^{MLMC}(\varepsilon) = \begin{cases} O(\varepsilon^{-2}) & \text{si } \beta > \gamma, \\ O(\varepsilon^{-2}(\log \varepsilon)^2) & \text{si } \beta = \gamma, \\ O(\varepsilon^{-2-(\gamma-\beta)/\alpha}) & \text{si } \beta < \gamma, \end{cases} \quad (36)$$

et le nombre optimal de scénarios par niveau est :

$$N_l^* = \left\lceil 2 \varepsilon^{-2} \sqrt{V_l / \mathcal{C}_l} \sum_{l'=0}^L \sqrt{V_{l'} \mathcal{C}_{l'}} \right\rceil. \quad (37)$$

Esquisse. On décompose la MSE en biais et variance :

$$\text{MSE} = \underbrace{|\mathbb{E}[\text{H}(-Y_L)] - \mathbb{P}(L > c)|^2}_{\text{biais}^2} + \underbrace{\text{Var}(\hat{\eta}_L^{\text{MLMC}})}_{\text{variance}} \leq \varepsilon^2.$$

La condition (i) impose le niveau maximal $L \geq \alpha^{-1} \log_M(\varepsilon^{-1} \sqrt{2} C_1)$ pour contrôler le biais en $\varepsilon^2/2$. On minimise ensuite $\sum_l N_l C_l$ sous la contrainte $\sum_l V_l/N_l \leq \varepsilon^2/2$ par inégalité de Cauchy-Schwarz, ce qui donne (37). La substitution dans le coût total et la sommation sur les $L + 1$ niveaux donnent les trois régimes selon la valeur de β relativement à γ . $\square$

3.4. La difficulté du quantile : discontinuité et échantillonnage adaptatif

La variable $\text{H}(-Y_l) - \text{H}(-Y_{l-1})$ est nulle sauf lors d'un *crossing event* : quand Y_l et Y_{l-1} sont de signes opposés, c'est-à-dire quand les deux estimateurs se contredisent sur le signe de $\mathbb{E}^Q[X | Y]$. Puisque $\text{H}(-Y_l) - \text{H}(-Y_{l-1}) \in \{-1, 0, 1\}$, la variance de cette différence est bornée par la probabilité d'un crossing event :

$$V_l = \text{Var}[\text{H}(-Y_l) - \text{H}(-Y_{l-1})] \leq \mathbb{P}(Y_l \text{ et } Y_{l-1} \text{ de signes opposés}).$$

Par le TCL, la précision de Y_l croissant en $K_l^{1/2}$, la probabilité que Y_l change de signe par rapport à Y_{l-1} est $O(K_l^{-1/2})$, d'où :

$$V_l = O(K_l^{-1/2}) = O(M^{-l/2}), \quad (38)$$

soit $\beta = 1/2$. Avec $\gamma = 1$ (coût proportionnel à K_l), on est dans le cas $\beta < \gamma$:

$$\mathcal{C}_{\text{sans adaptation}}^{\text{MLMC}}(\varepsilon) = O(\varepsilon^{-3}). \quad (39)$$

Sans adaptation, MLMC ne fait pas mieux que les simulations imbriquées en termes de complexité.

La solution : l'échantillonnage adaptatif (Broadie-Du-Moallemi / Giles-Haji-Ali)

(BROADIE, DU et MOALLEMI 2011) ont observé que le biais est concentré sur les scénarios où $\mathbb{E}^Q[X | Y]$ est proche de zéro — les scénarios *ambigus*, pour lesquels un faible nombre de simulations internes suffit à générer un crossing event. Leur idée est d'allouer plus de simulations internes à ces scénarios pour réduire la probabilité de les classer du mauvais côté du seuil.

(GILES et HAJI-ALI 2019) formalisent cette idée dans le cadre MLMC via le rapport signal/bruit :

$$\delta(y) := \frac{|\mathbb{E}^Q[X | Y = y]|}{\text{Var}^Q[X | Y = y]^{1/2}}, \quad (40)$$

et un algorithme qui alloue $N_l(y)$ simulations internes adaptativement : grand quand $\delta(y)$ est petit (scénario ambigu), petit quand $\delta(y)$ est grand (scénario clairement classé). Sous des conditions de régularité, cela restaure :

$$\mathbb{E}[N_l(Y)] = O(M^l), \quad V_l = O(M^{-l}), \quad (41)$$

soit $\beta = \gamma = 1$.

Proposition 3.2 (Complexité avec adaptation, (GILES et HAJI-ALI 2019)). *L'estimateur MLMC avec échantillonnage adaptatif atteint :*

$$\mathcal{C}_{\text{adaptatif}}^{\text{MLMC}}(\varepsilon) = O(\varepsilon^{-2} |\log \varepsilon|^2). \quad (42)$$

Le contraste entre (39) et (42) illustre l'apport de l'adaptation : sans elle, MLMC partage le même exposant ε^{-3} que les simulations imbriquées ; avec elle, il atteint presque $O(\varepsilon^{-2})$.

3.5. Valeurs théoriques de α, β, γ

Si l'on discrétisait le modèle Black-Scholes / Vasicek par un schéma d'Euler-Maruyama à pas $\Delta t_l = 1/K_l$, les trois paramètres prendraient les valeurs : $\gamma = 1$ (coût proportionnel à K_l), $\alpha = 1$ (erreur faible d'Euler en $O(\Delta t)$), et $\beta = 1/2$ sans adaptation d'après (38), soit une complexité $O(\varepsilon^{-3})$ sans adaptation, et $\beta = 1$ avec adaptation, soit $O(\varepsilon^{-2} |\log \varepsilon|^2)$.

L'implémentation numérique de cette méthode n'a pas encore été menée à terme ; aucun résultat numérique n'en est donc présenté en section 4.

4. Implémentation et résultats

4.1. Modèle actif-passif

Nous nous plaçons dans le cadre d'un portefeuille de contrats d'assurance vie avec participation aux bénéfices, tel que modélisé par (BAUER, KIESEL et al. 2006). L'assureur collecte une prime initiale $L_0 = 10\,000$ et constitue une réserve initiale $R_0 = x_0 L_0 = 1\,000$ ($x_0 = 10\%$), si bien que les actifs initiaux sont $A_0 = L_0 + R_0 = 11\,000$. Le contrat garantit un taux minimum $g = 3,5\%$ sur les engagements, une participation minimale $\delta = 90\%$ aux bénéfices, et arrive à maturité en $T = 10$ ans.

Modèle d'actifs et de taux

Les actifs suivent une dynamique de Black-Scholes et le taux sans risque un processus de Vasicek, les deux étant corrélés. Sous la mesure historique $\mathbb{P}$:

$$\begin{cases} dA_t = \mu A_t dt + \sigma_A A_t dW_t^A, \\ dr_t = \kappa(\xi - r_t) dt + \sigma_r dW_t^r, \end{cases} \quad d\langle W^A, W^r \rangle_t = \rho dt, \quad (43)$$

où μ est le rendement espéré des actifs, κ la vitesse de retour à la moyenne du taux, ξ son niveau d'équilibre de long terme, et ρ le coefficient de corrélation entre actifs et taux. On peut écrire $W_t^A = \rho W_t^1 + \sqrt{1 - \rho^2} W_t^2$ avec $W^1 = W^r$ et $W^2 \perp W^r$.

Sous la mesure risque-neutre $\mathbb{Q}$, le changement de mesure de Girsanov (avec prix de risque constant λ) modifie la moyenne de long terme du taux : $\tilde{\xi} = \xi - \lambda \sigma_r / \kappa$. Les dynamiques deviennent :

$$\begin{cases} dA_t = r_t A_t dt + \rho \sigma_A A_t d\tilde{W}_t^1 + \sqrt{1 - \rho^2} \sigma_A A_t d\tilde{W}_t^2, \\ dr_t = \kappa(\tilde{\xi} - r_t) dt + \sigma_r d\tilde{W}_t^1. \end{cases} \quad (44)$$

Le modèle de Vasicek présente l'avantage d'admettre une solution explicite sous $\mathbb{Q}$:

$$r_t = r_s e^{-\kappa(t-s)} + \tilde{\xi}(1 - e^{-\kappa(t-s)}) + \sigma_r \int_s^t e^{-\kappa(t-u)} d\tilde{W}_u^1, \quad (45)$$

ce qui implique que le facteur d'actualisation $B_{s,t}^{-1}$ est lognormal sous $\mathbb{Q}$ et permet des simulations exactes — sans discrétisation numérique.

Calibration

Les paramètres du modèle sont repris de (BAUER, KIESEL et al. 2006), estimés sur données allemandes (juin 1998 – juin 2008) à partir d'un portefeuille proxy composé à 80% de l'indice obligataire REXP et à 20% de l'indice actions DAX. La méthode d'estimation utilisée par les auteurs (vraisemblance maximale sur séries temporelles) dépasse le cadre de ce travail; nous nous contentons d'en reprendre les valeurs.

Les paramètres obtenus sont les suivants :

$$\mu = 4,25\%, \quad \sigma_A = 4,28\%, \quad \kappa = 14,49\%, \quad \xi = 3,64\%, \quad \sigma_r = 0,60\%, \quad r_0 = 4,19\%, \\ \rho = -0,0597, \quad \lambda = -0,5061.$$

Leur interprétation économique est assez parlante : le rendement espéré des actifs ($\mu = 4,25\%$) est légèrement supérieur au taux initial ($r_0 = 4,19\%$), reflétant une prime de risque actions modérée sur la période. La faible volatilité du taux ($\sigma_r = 0,60\%$) et la vitesse de retour à la moyenne élevée ($\kappa = 14,49\%$) traduisent un taux d'intérêt relativement stable autour de son niveau d'équilibre $\xi = 3,64\%$. La corrélation négative ($\rho = -0,0597$) entre actifs et taux est cohérente avec le comportement observé : une hausse des taux tend à peser sur les prix des actifs. Enfin, le prix de marché du risque négatif ($\lambda = -0,5061$) indique que les investisseurs exigent une prime pour détenir des obligations longues, ce qui est conforme à la théorie des préférences de liquidité.

4.2. Résultats

Simulations imbriquées

Avec les paramètres de (BAUER, BERGMANN et REUSS 2010) : $K_0 = 1,5 \times 10^6$, $N = 320\,000$, $K_1 = 300$, nous obtenons :

Résultats clés

$\widehat{\text{SCR}}^{\text{Nested}} \approx 1\,322$ Temps : **79,28 s** Biais théorique : $\theta_\alpha / (K_1 f_L) > 0$ (Théorème 2.1).

Les auteurs obtiennent quant à eux $\widehat{\text{SCR}} \approx 1\,249,3$ avec les mêmes paramètres, soit un écart d'environ 6% avec notre estimation. Plusieurs raisons peuvent l'expliquer : les approximations introduites dans notre implémentation sur la modélisation des flux actionnariaux et l'actualisation; une possible différence dans la convention de quantile empirique; et le fait que les auteurs travaillent avec l'estimateur basé sur les flux assurés plutôt que les flux actionnariaux, ce dernier étant plus dispersé et conduisant à un SCR plus élevé, comme ils le montrent eux-mêmes (Table 2 de (BAUER, BERGMANN et REUSS 2010)).

Au-delà du simple calcul du SCR, (BAUER, BERGMANN et REUSS 2010) conduisent une analyse plus approfondie que la nôtre sur trois points. Ils étudient d'abord l'impact du nombre de simulations internes K_1 sur la qualité de l'estimateur : pour $K_1 = 1$, le SCR est surestimé à 1 994; il converge vers 1 246

pour $K_1 = 1\,000$, validant empiriquement le caractère décroissant du biais en $O(K_1^{-1})$ prédit par le Théorème 2.1. Ils procèdent ensuite à une analyse de sensibilité sur le couple (N, K_1) à budget total fixé $\Gamma = 97,500,000$: en répétant l'estimation 150 fois pour chaque combinaison, ils identifient empiriquement le couple qui minimise la MSE, soit $(N = 320,000, K_1 = 300)$, cohérent avec les prédictions de l'optimisation par Lagrangien. Enfin, ils corrigent le biais de l'estimateur en retranchant le terme dominant :

$$\widehat{\text{SCR}}_{\text{cor}} = \widehat{\text{SCR}} - \frac{\hat{\theta}_\alpha}{K_1 \cdot \hat{f}(\text{SCR})}, \quad (46)$$

où $\hat{\theta}_\alpha$ est estimé par régression quadratique de $\mathbb{E}^\mathbb{Q}[\sigma_1^2 \mid L]$ et $\hat{f}(\text{SCR})$ par différences finies sur la distribution empirique. Ils obtiennent ainsi $\widehat{\text{SCR}}_{\text{cor}} = 1\,246,4$, valeur retenue comme référence pour les comparaisons ultérieures.

MLMC

L'implémentation numérique de la méthode MLMC n'a pas encore été menée à terme ; aucun résultat numérique n'est donc présenté.

Conclusion

Ce rapport a étudié le problème de l'estimation du SCR par modèle interne, en s'appuyant sur une analyse mathématique rigoureuse des méthodes en jeu.

Les **simulations imbriquées** ($O(\varepsilon^{-3})$) constituent la méthode de référence : le Théorème 2.1 établit formellement le biais positif de l'estimateur et en dérive l'expression asymptotique ; l'optimisation par multiplicateurs de Lagrange donne les allocations optimales (K_0^*, N^*) .

La méthode **MLMC**, fondée sur l'identité télescopique et l'échantillonnage adaptatif, permettrait d'atteindre $O(\varepsilon^{-2} |\log \varepsilon|^2)$ — un gain théorique significatif. Son implémentation numérique reste à compléter et constitue la première extension naturelle de ce travail.

Références

- BAUER, Daniel, Daniela BERGMANN et Andreas REUSS (2010). « Solvency II and Nested Simulations - a Least-Squares Monte Carlo Approach ». In : *Journal of Risk and Insurance* 77.3. First version : October 2008, This version : January 2010., p. 665-684.
- BAUER, Daniel, Rüdiger KIESEL et al. (2006). « Risk-neutral valuation of participating life insurance contracts ». In : *Insurance : Mathematics and Economics* 39, p. 171-183.
- BROADIE, Mark, Yiping DU et Ciamac C. MOALLEMI (2011). « Efficient risk estimation via nested sequential simulation ». In : *Management Science* 57.6, p. 1172-1194. DOI : [10.1287/mnsc.1110.1330](https://doi.org/10.1287/mnsc.1110.1330).
- GILES, Michael B. (2008). « Multilevel Monte Carlo path simulation ». In : *Operations Research* 56.3, p. 607-617. DOI : [10.1287/opre.1070.0496](https://doi.org/10.1287/opre.1070.0496).
- (2015). « Multilevel Monte Carlo methods ». In : *Acta Numerica* 24, p. 259-328. DOI : [10.1017/S096249291500001X](https://doi.org/10.1017/S096249291500001X).
- GILES, Michael B. et Abdul-Lateef HAJI-ALI (2019). « Multilevel nested simulation for efficient risk estimation ». In : *SIAM/ASA Journal on Uncertainty Quantification* 7.2, p. 497-525. DOI : [10.1137/18M1173186](https://doi.org/10.1137/18M1173186).
- GORDY, Michael B. et S. JUNEJA (2010). « Nested simulations in portfolio risk measurement ». In : *Management Science* 56.10, p. 1833-1848.